멋쟁이 사자처럼 데이터분석 5기 파이널프로젝트

신용카드 고객 세그먼트 예측 프로젝트

12조
박상현
엄다현
우지원
이세윤

LIKELION DATA ANALYSIS SCHOOL

목차

Table of Contents

1 프로젝트 개요

2 데이터 소개

3 데이터 전처리 및 피처 선택

4 모델링

단일/파이프라인 모델링
모델링 최적화

5 한계점 및 개선방향

6 EDA 및 마케팅전략

1. 프로젝트 개요

1. 프로젝트 목적

- 고객의 특성을 나타내는 변수 중 “세그먼트 분류에 주요한 영향을 미치는 컬럼을 도출”

2. 결과 활용 방향

- 고객 특성 분석을 통해 “세그먼트별 차별화된 마케팅 전략 수립 제안”

2. 데이터 소개

Data Overview

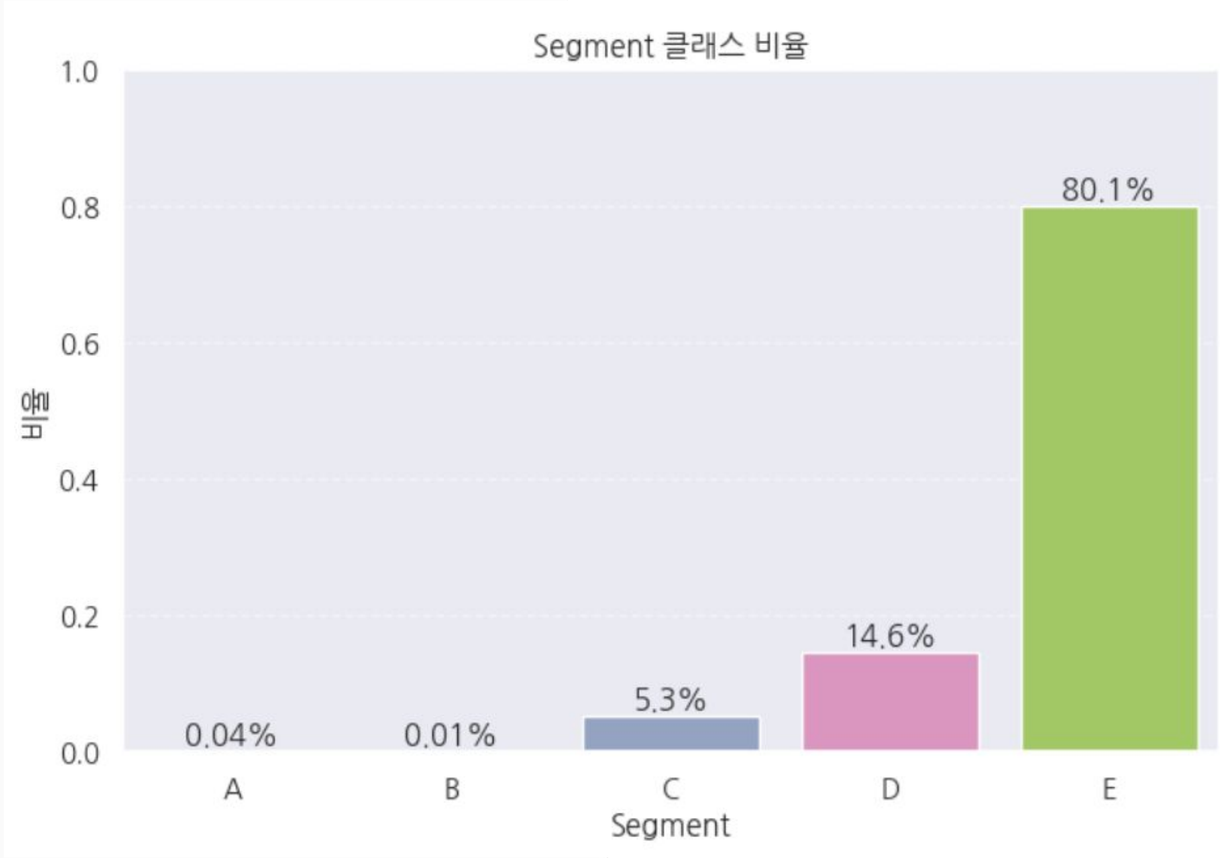
Train
ID : 400,000
Month : 6

Test
ID : 100,000
Month : 1

1. 회원정보(77개 칼럼) + segment
2. 신용정보(42개 컬럼)
3. 승인매출정보(406개 컬럼)
4. 청구입금정보(46개 컬럼)
5. 잔액정보(82개 컬럼)
6. 채널정보(105개 컬럼)
7. 마케팅정보(64개 컬럼)
8. 성과정보(49개 컬럼)

Segment(타겟 변수) : 고객 유형 분류를 위한 라벨

2. 데이터 소개



E는 전체 데이터의 80%, A / B는 매우 적은 불균형 데이터

3. 데이터 전처리 및 피처 선택

Data Preprocessing and Feature Selection

과정	세부내용	피처 수
결측치 제거	결측값이 포함된 컬럼 제거	**674개**
동일값 컬럼 제거	모든 행이 동일한 값인 컬럼 제거 (기준년월 제외)	
범주형 처리	Label Encoding 수행	
상관계수	○ 절댓값 0.2 미만 → 예측 변수로서 기여도 낮은 컬럼 제거 ○ Segment 컬럼을 One-Hot Encoding 하여 각 Segment 별 상관관계 분석	**227개**
VIF (분산팽창지수)	○ VIF 10 초과 변수 중복 제거 ○ 다중공선성 제거로 모델 안정성 확보	**35개**

데이터 전처리 및 피처 선택

Data Preprocessing and Feature Selection

Feature vs Segment_A~E 상관관계

	Segment_A	Segment_B	Segment_C	Segment_D	Segment_E
소지카드수_유효_신용	0.03	0.01	0.24	0.21	-0.32
소지카드수_이용가능_신용	0.03	0.01	0.22	0.21	-0.31
입회경과개월수_신용	0.04	0.01	0.19	0.14	-0.23
이용금액_R3M_신용_가족	0.04	0.01	0.20	0.11	-0.21
이용여부_3M_해외겸용_본인	0.02	0.01	0.14	0.18	-0.24
이용여부_3M_해외겸용_신용_본인	0.02	0.01	0.14	0.17	-0.23
2순위신용체크구분_인코딩	0.01	0.00	0.14	0.19	-0.25
CA한도금액	0.05	0.01	0.22	0.16	-0.27
최종이용일자_CA	0.01	0.01	0.14	0.16	-0.22
최종이용일자_할부	0.01	0.00	0.11	0.17	-0.21
이용후경과월_CA	-0.02	-0.01	-0.17	-0.15	0.23
최대이용금액_일시불_R12M	0.08	0.02	0.38	0.25	-0.44
최대이용금액_할부_유이자_R12M	0.01	0.00	0.12	0.16	-0.20
쇼핑_백화점_이용금액	0.05	0.02	0.21	0.16	-0.26
쇼핑_마트_이용금액	0.04	0.02	0.28	0.25	-0.38
쇼핑_슈퍼마켓_이용금액	0.04	0.02	0.26	0.27	-0.38
쇼핑_편의점_이용금액	0.03	0.01	0.21	0.24	-0.33
쇼핑_기타_이용금액	0.03	0.02	0.19	0.20	-0.29

	Segment_A	Segment_B	Segment_C	Segment_D	Segment_E
교통_정비이용금액	0.04	0.01	0.24	0.21	-0.32
교통_택시이용금액	0.03	0.01	0.16	0.18	-0.25
여유_운동이용금액	0.05	0.02	0.19	0.14	-0.23
납부_기타이용금액	0.07	0.02	0.24	0.16	-0.28
_1순위업종_이용금액	0.08	0.04	0.34	0.27	-0.44
_2순위업종_이용금액	0.07	0.02	0.35	0.30	-0.46
_3순위업종_이용금액	0.08	0.02	0.36	0.30	-0.48
_2순위교통업종_이용금액	0.03	0.01	0.23	0.25	-0.35
_3순위교통업종_이용금액	0.04	0.01	0.23	0.21	-0.31
_1순위여유업종_이용금액	0.06	0.02	0.22	0.15	-0.26
_1순위납부업종_이용금액	0.02	0.01	0.14	0.18	-0.24
RP건수_B0M	0.01	0.01	0.12	0.17	-0.22
RP유형건수_B0M	0.01	0.00	0.11	0.16	-0.20
이용개월수_온라인_R6M	0.02	0.01	0.19	0.25	-0.33
연속유실적개월수_기본_24M_카드	0.02	0.01	0.20	0.29	-0.37
청구서발송여부_B0	0.01	0.00	0.11	0.18	-0.22
잔액_일시불_B2M	0.04	0.01	0.27	0.23	-0.36

4. 단일 모델링

Single Modeling

1. LightGBM
2. XGBoost
3. CatBoost

선택 이유

- Gradient Boosting 수행하기 때문에 복잡한 비선형 관계도 효과적으로 학습
- 다양한 데이터셋에서 우수한 성능이 입증된 알고리즘

단일 모델링

LightGBM

Validation F1 score (micro)	**0.8432**

Confusion Matrix (Validation Set)

	예측_A	예측_B	예측_C	예측_D	예측_E
실제_A	11	0	172	11	0
실제_B	0	0	27	1	1
실제_C	147	8	11088	9119	5156
실제_D	72	23	5505	32277	31971
실제_E	20	21	2270	20747	361353

E는 예측을 잘하는 반면,
A, B, C, D는 예측을 못하는 것들이 꽤 많음

단일 모델링

XGBoost

Validation F1 score (micro)	**0.8700**

Confusion Matrix (Validation Set)

	예측_A	예측_B	예측_C	예측_D	예측_E
실제_A	78	0	116	0	0
실제_B	0	7	22	0	0
실제_C	4	1	12482	8398	4633
실제_D	2	0	4287	34515	31044
실제_E	1	0	1202	12703	370505

E는 높은 예측 정확도를 보이는 반면,
A와 B는 특히 C로 오분류 되는 경향을 보임

단일 모델링

CatBoost

Validation F1 score (micro)	**0.8711**

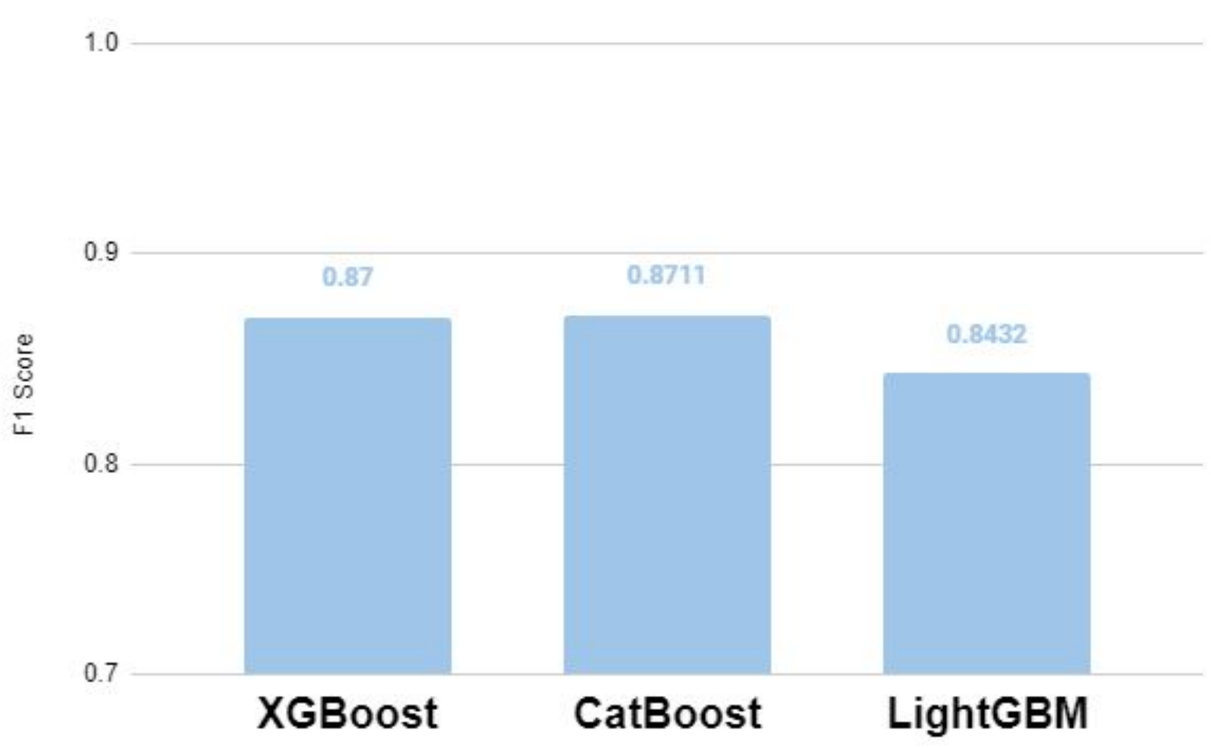
Confusion Matrix (Validation Set)

	예측_A	예측_B	예측_C	예측_D	예측_E
실제_A	85	0	109	0	0
실제_B	0	13	16	0	0
실제_C	4	0	12461	8430	4623
실제_D	1	0	4076	34744	31027
실제_E	1	0	1133	12475	370802

E 의 정확도는 높은 반면
나머지 A~D 의 정확도는 아쉬움

단일 모델링 분석

Analysis of the Single Modeling



CatBoost 성능 우수

불균형 데이터 처리에 가장 우수한 성능

A~D 예측 정확도 떨어짐

클래스 간 복잡도 차이, 불균형으로 예측 정확도 저하되었을 가능성

CatBoost 기반 파이프라인 모델 제안

복잡한 전체 분류 문제를 작은 이진/삼중 분류로 분해,
각 단계별로 모델을 학습시켜 전체 예측 정확도 향상시키고자 함

파이프라인 모델링

Pipeline Modeling

CatBoost 기반 2단계 파이프라인

1단계: Model1

TrainData1: 전체 데이터 C/D/E + Other(A,B)로 구성

C,D,E 예측결과는 그대로 사용
Other 예측 결과 → Model2로 전달

2단계: Model2

TrainData2: A/B만 포함

예측 A,B 결과로 사용

최종 결과 | Model1 결과 + Model2 결과

파이프라인 모델링

Pipeline Modeling

단일 모델링

Validation F1 Score (micro): 0.8711

	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	85	0	109	0	0	0.4381
실제_B	0	13	16	0	0	0.4483
실제_C	4	0	12461	8430	4623	0.4883
실제_D	1	0	4076	34744	31027	0.4974
실제_E	1	0	1133	12475	370802	0.9646

2단계 파이프라인 모델링

Validation F1 Score (micro): 0.8710

	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	76	0	118	0	0	0.3918
실제_B	0	6	23	0	0	0.2069
실제_C	6	0	12499	8386	4627	0.4898
실제_D	1	0	4073	34720	31054	0.4971
실제_E	1	0	1116	12508	370786	0.9646

결과

- 두 모델 모두 A,B를 C로 오분류하는 경우 많음
- 두 모델 모두 C,D 예측 정확도 아쉬움

파이프라인 모델링

Pipeline Modeling

CatBoost 기반 3단계 파이프라인

1단계: Model1

TrainData1: 전체 데이터를
E + Other(E가 아닌것)로 구성

E 예측결과 사용
Other → Model2로 전달

2단계: Model2

TrainData2: E를 제외한 데이터
C,D+Other(A/B) 로 구성

C,D 예측결과 사용
Other → Model3로 전달

3단계: Model3

TrainData3: C,D,E 제외
A/B 로 구성

예측 A,B 결과로 사용

최종 결과 | Model1 결과 + Model2 결과 + Model3 결과

파이프라인 모델링

Pipeline Modeling

2단계 파이프라인 모델링

Validation F1 Score (micro): 0.8710

	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	76	0	118	0	0	0.3918
실제_B	0	6	23	0	0	0.2069
실제_C	6	0	12499	8386	4627	0.4898
실제_D	1	0	4073	34720	31054	0.4971
실제_E	1	0	1116	12508	370786	0.9646

3단계 파이프라인 모델링

Validation F1 Score (micro): 0.8711

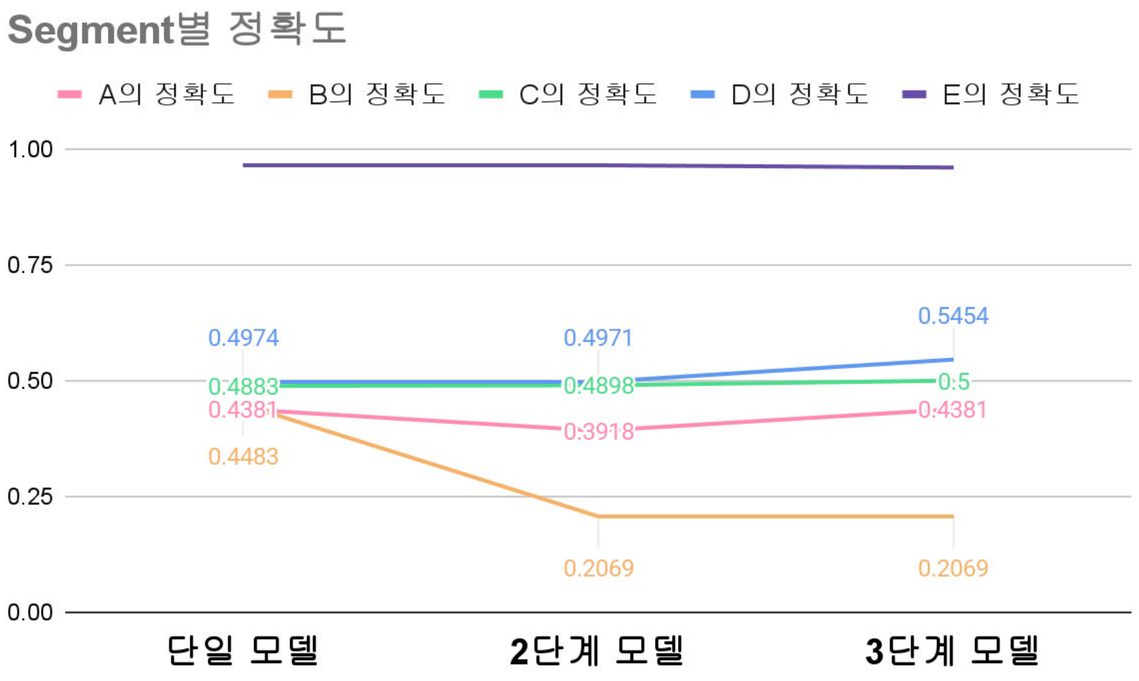
	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	85	0	109	0	0	0.4381
실제_B	1	6	22	0	0	0.2069
실제_C	6	0	12760	9053	3699	0.5000
실제_D	0	0	4082	38092	27674	0.5454
실제_E	2	0	1266	14221	368922	0.9597

결과

- 두 모델 모두 A,B를 C로 오분류하는 경우 많음
- E의 정확도가 감소하였지만 C,D의 정확도 증가

파이프라인 모델링 분석

Analysis of the Pipeline Modeling



A,B를 C로 오분류하는 경우 많음

모든 모델에서 A,B를 과반수 이상 C로 잘못 예측
A,B의 데이터가 상대적으로 적기 때문에 제대로 학습되지 못했을 가능성

C,D의 예측 정확도가 낮음

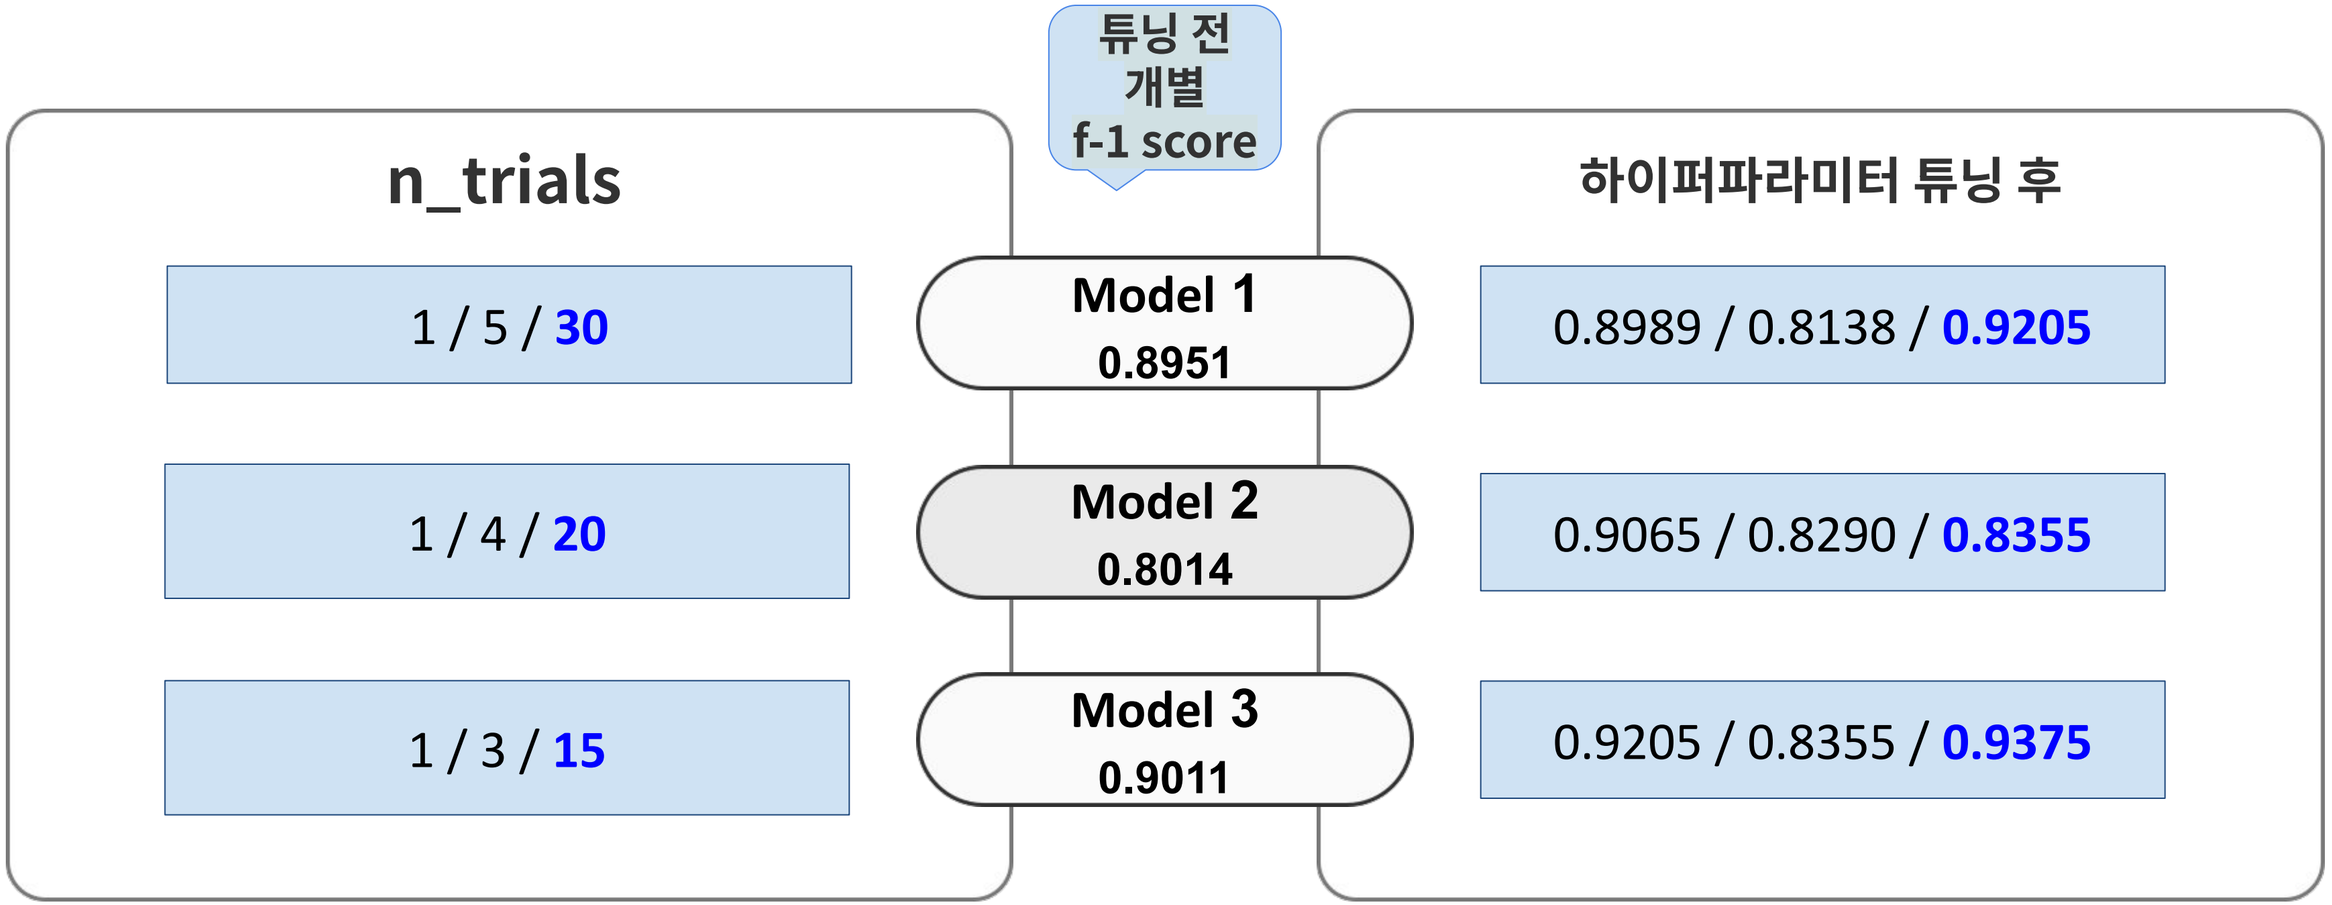
모든 모델에서 C,D를 제대로 예측 못함
3단계 파이프라인 모델에서 C,D 정확도가 가장 높음

3단계 파이프라인 모델 최적화 제안

C,D의 정확도가 가장 높았던 3단계 파이프라인 모델을 선택
하이퍼 파라미터 튜닝을 통해 학습 모델 최적화
2단계 학습시 **가중치를 적용**하여 데이터가 적은 클래스의 학습 성능 향상

모델 최적화 - 개별 모델 하이퍼파라미터 튜닝(optuna)

Model Optimization



모델 최적화 - 하이터터파라미터 튜닝 적용

Model Optimization

3단계 파이프라인 모델링 - 기본

Validation F1 Score (micro): 0.8711

	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	85	0	109	0	0	0.4381
실제_B	1	6	22	0	0	0.2069
실제_C	6	0	12760	9053	3699	0.5000
실제_D	0	0	4082	38092	27674	0.5454
실제_E	2	0	1266	14221	368922	0.9597

3단계 파이프라인 모델링 - 튜닝 적용

Validation F1 Score (micro): 0.8939

	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	105	0	89	0	0	0.5412
실제_B	1	9	19	0	0	0.3103
실제_C	3	0	13471	8964	3080	0.5279
실제_D	0	0	3634	42591	23623	0.6098
실제_E	0	0	1054	10480	372877	0.9700

결과

- 전체적으로 성능 향상

모델 최적화 - 가중치, 파라미터 튜닝 적용

Model Optimization

3단계 파이프라인 모델링 - 튜닝적용

Validation F1 Score (micro): 0.8939

	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	105	0	89	0	0	0.5412
실제_B	1	9	19	0	0	0.3103
실제_C	3	0	13471	8964	3080	0.5279
실제_D	0	0	3634	42591	23623	0.6098
실제_E	0	0	1054	10480	372877	0.9700

3단계 파이프라인 모델링 - 가중치, 튜닝 적용

Validation F1 Score (micro): 0.8885

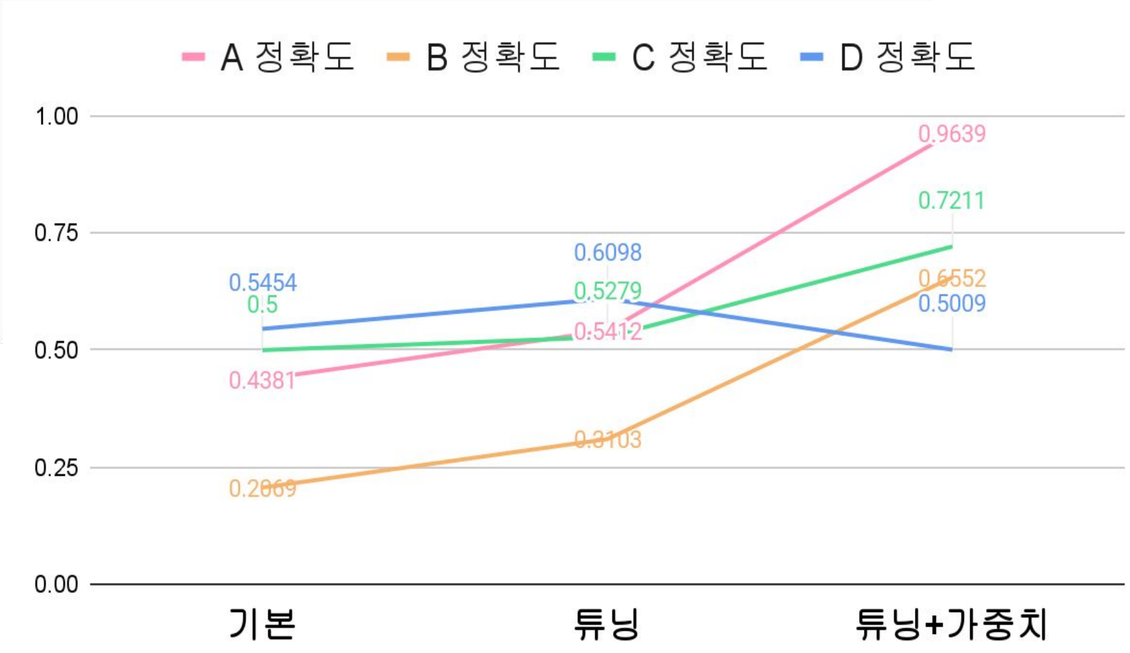
	예측 A	예측 B	예측 C	예측 D	예측 E	클래스별 정확도
실제_A	187	1	6	0	0	0.9639
실제_B	3	19	7	0	0	0.6552
실제_C	147	7	18401	3883	3080	0.7211
실제_D	17	0	11224	34984	23623	0.5009
실제_E	11	1	2922	8600	372877	0.9700

결과

- A,B를 C로 오분류하는 경우 감소 -> A,B의 정확도 향상
- C를 D로 오분류하는 경우 감소 -> C의 정확도 향상
- D를 C로 오분류하는 경우 증가 -> D의 정확도 저하

모델 최적화 분석

Analysis of the Model Optimization



A,B,C 예측 정확도 개선

A,B -> C 로 오분류 되는 경우 감소
C -> D 로 오분류 되는 경우 감소

D 예측 정확도 저하

D -> C 로 오분류 되는 경우 증가

최종 학습 모델(튜닝+가중치) 채택

VIP클래스로 예상되는 A,B -> C 로 오분류 되는 것 보다
D -> C 로 오분류 되는 것이 리스크가 작음

5. 한계점 및 개선방향

Limitations and Improvement Plans

최종 모델

VIF가 높은 피처들 제거
-> 예측에 주요한 피처가 제거되었을 가능성

A, B/C, D/E 분류의 파이프라인 모델
-> A,E 높은 정확도 / D의 정확도 아쉬움
-> 앞 단계에서 분류가 잘못된 경우 보완 불가능

하이퍼파라미터 튜닝은 모델별로 최적의 파라미터 범위와 횟수 수동 선택

D 세그먼트의 분류 정확도는 저하라는 한계가 있음

피처 선택

파이프라인 설계

하이퍼파라미터

딥러닝

개선 방향

각 Segment 별 피처 중요도, SHAP value 분석을 통해 최종 모델에 주요 피처 추가하는 방안

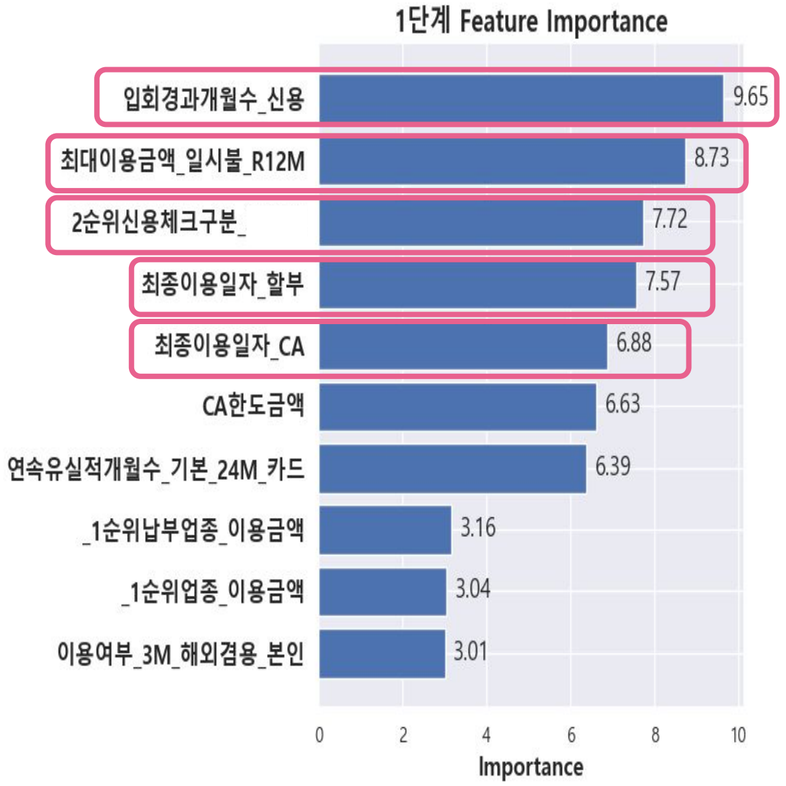
각 클래스 이진분류 혹은 A, B, C/D/E 분류 모델 사용
전체 클래스별 proba로 가장 높은 확률 최종 채택

모델 선택부터 튜닝, 앙상블까지 전체 파이프라인을 자동화 할 수 있는 AutoML 사용

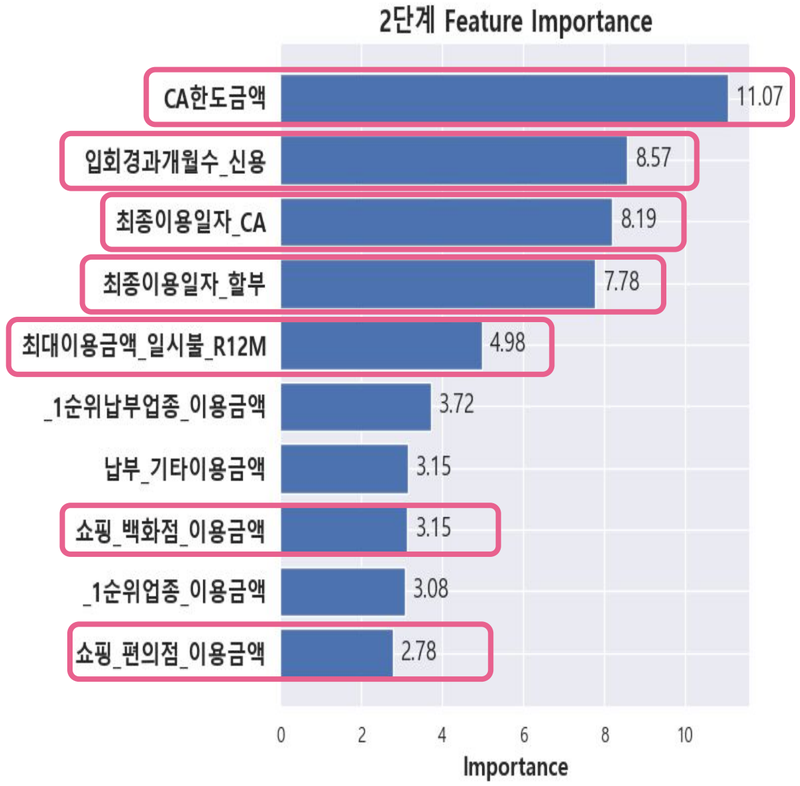
트리 기반 모델의 한계를 보완하기 위해,
변수간 복잡한 상호작용을 더 잘 학습할수 있는 다층 퍼셉트론 구조의 딥러닝 모델을 적용

6. EDA 및 마케팅 전략 - Feature Importance

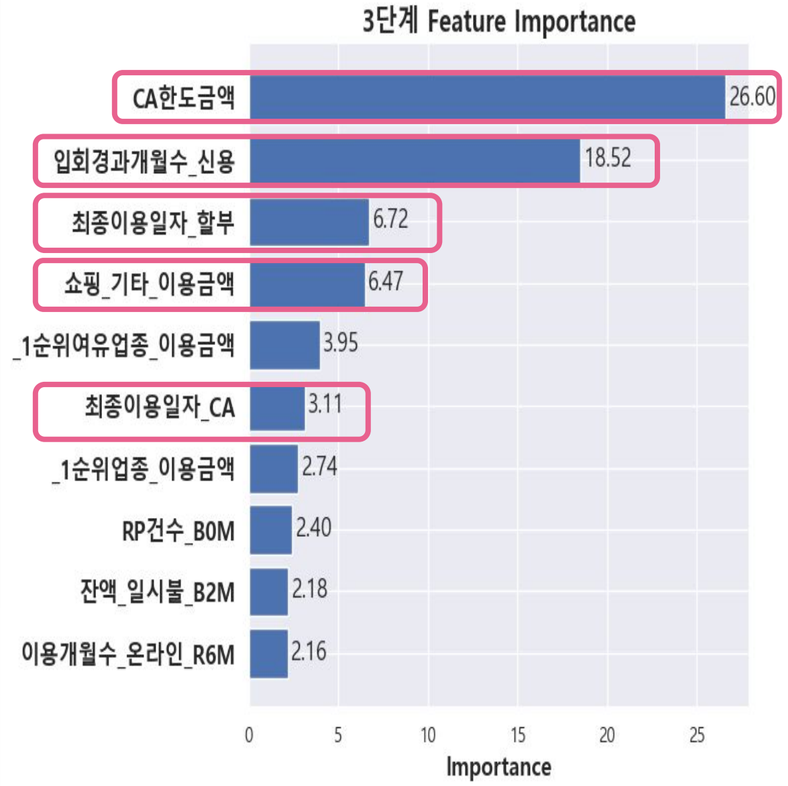
E,Other(A,B,C,D)
분류 피처 중요도



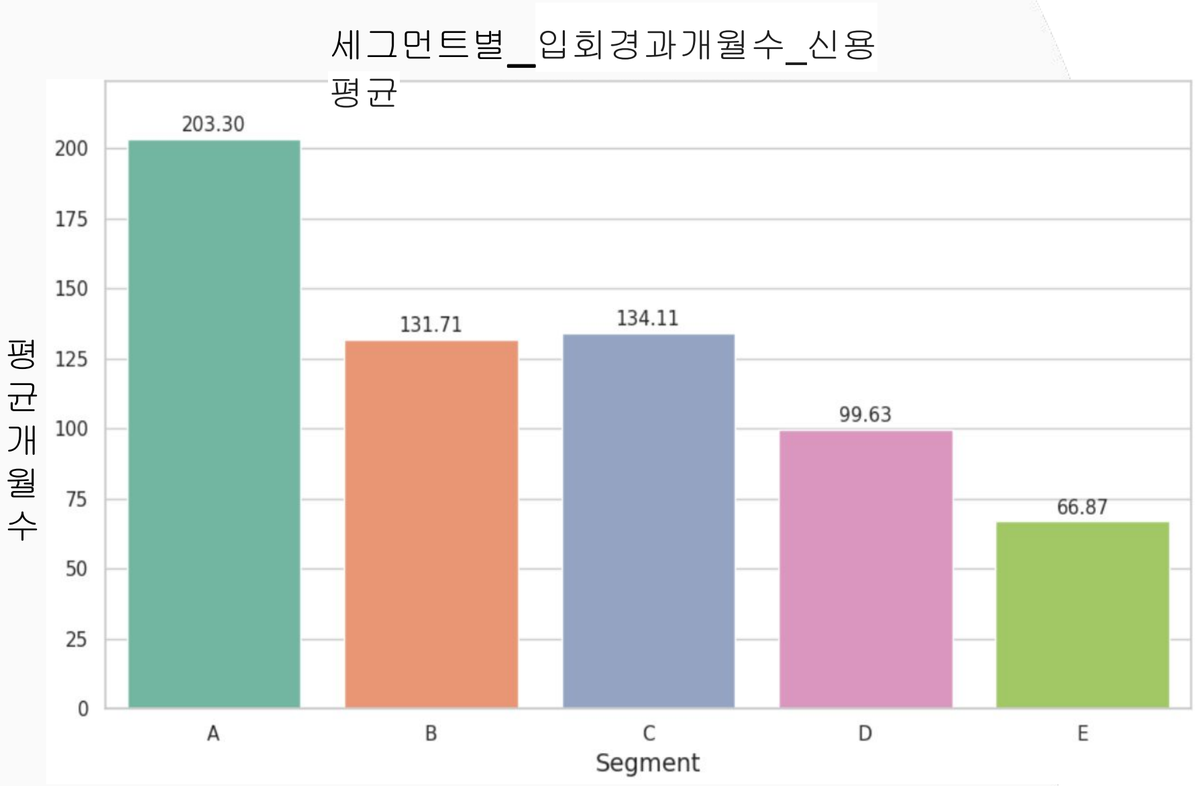
C,D,Other(A,B)
분류 피처 중요도



A,B
분류 피처 중요도



Feature EDA : 입회경과개월수_신용



→ **고객충성도** 및 **장기/신규고객 구분** 지표 활용

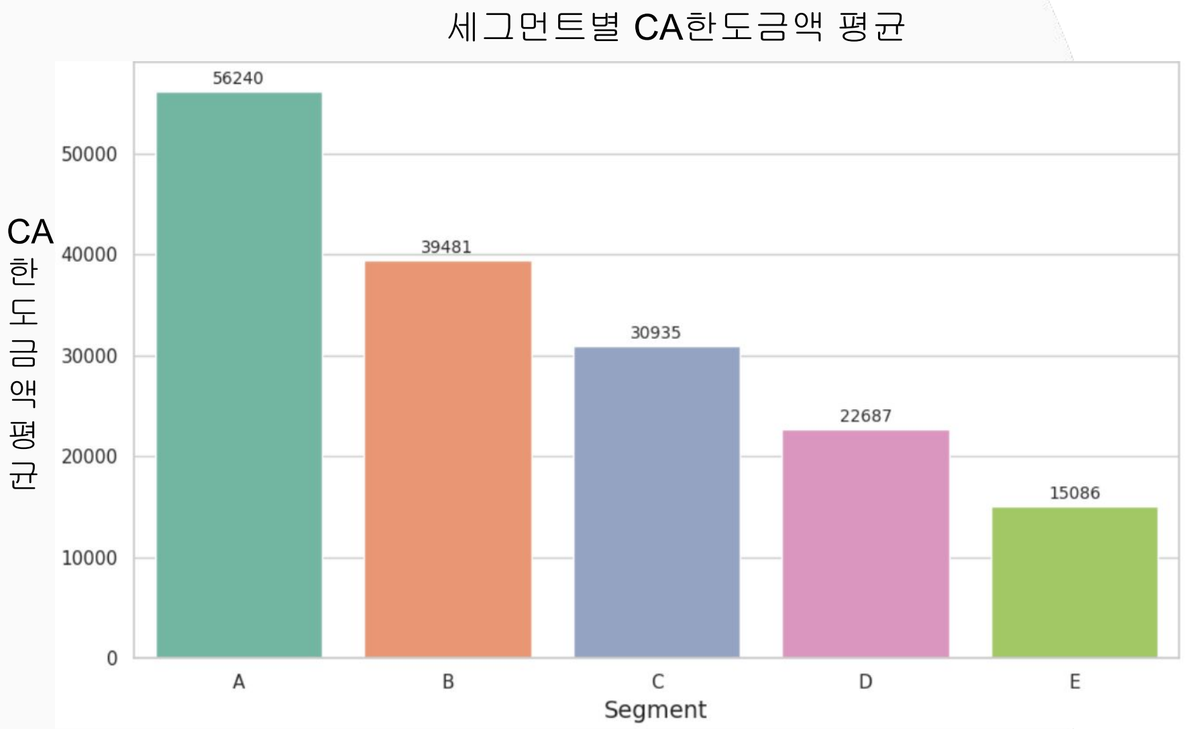
- **Segment A~C고객**

  안정적으로 이용하는 장기고객일 가능성 높음

- **Segment D~E 고객**

  비교적 최근에 유입된 신규고객일 가능성 높음

Feature EDA : CA한도금액



→ **신용도 및 소비여력의 지표로 활용**

- **CA한도금액 책정기준**

  신용도 / 소득 / 기존 거래 내역 등

- **A로 갈수록 CA 한도금액이 높음**

  → 고객의 신용 리스크가 낮고, 소득이 높을 가능성이 높음

  → 우량 고객일 가능성 높음

Feature EDA : 최대이용금액_일시불_R12M



- **소비 여력 및 신용도 반영 지표**

일시불로 고액 결제가 가능한 고객은 일반적으로 **소득수준이 높고, 신용 등급이 우수**

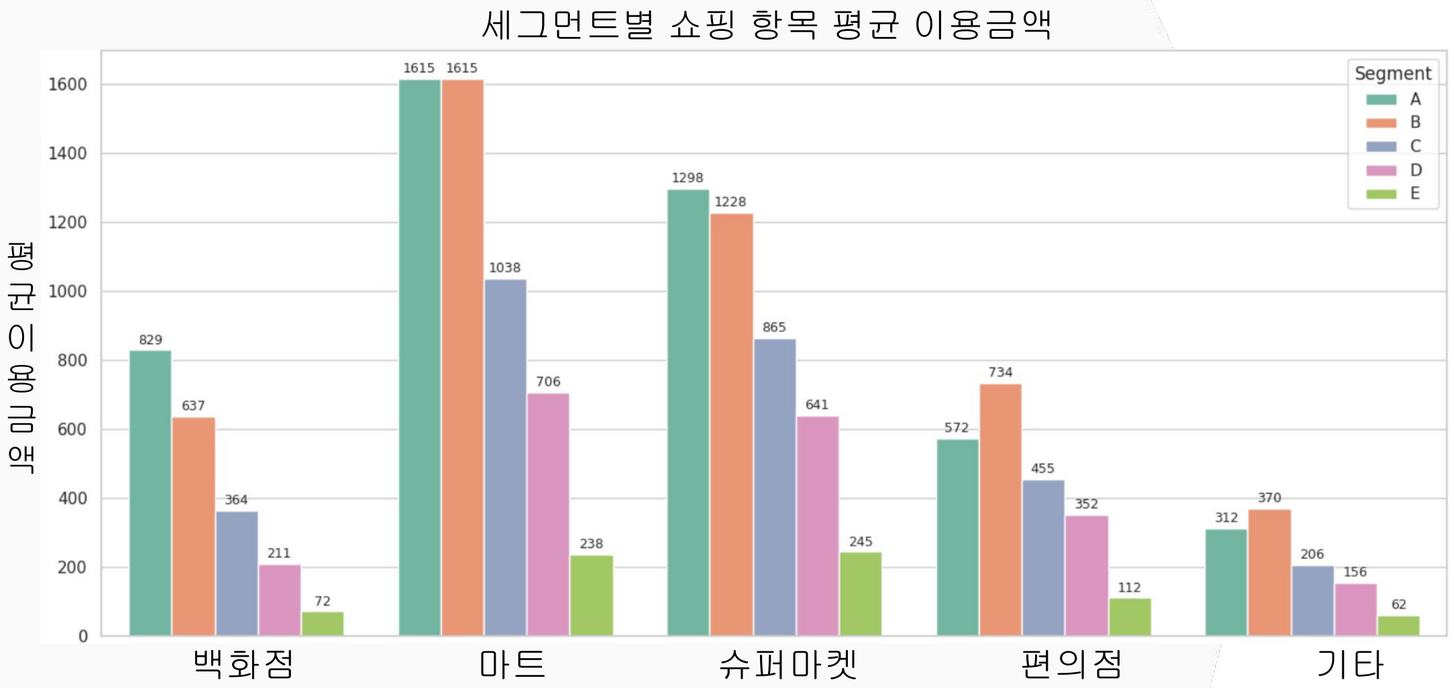
→ **우량고객**으로 분류될 가능성 높음

- **카드 사용 성향을 분명히 구분하는 변수**

ex) 예: 최근 1년 내 가장 큰 일시불 결제 금액이 “5만 원 이하인 고객"과 "70만 원 이상인 고객"은 명백히 **라이프스타일이 다르다.**

→ 카드사의 마케팅 분류 기준에서 이 변수는 **프리미엄 고객 탐색**을 핵심으로 활용 가능함

Feature EDA : 쇼핑_이용금액



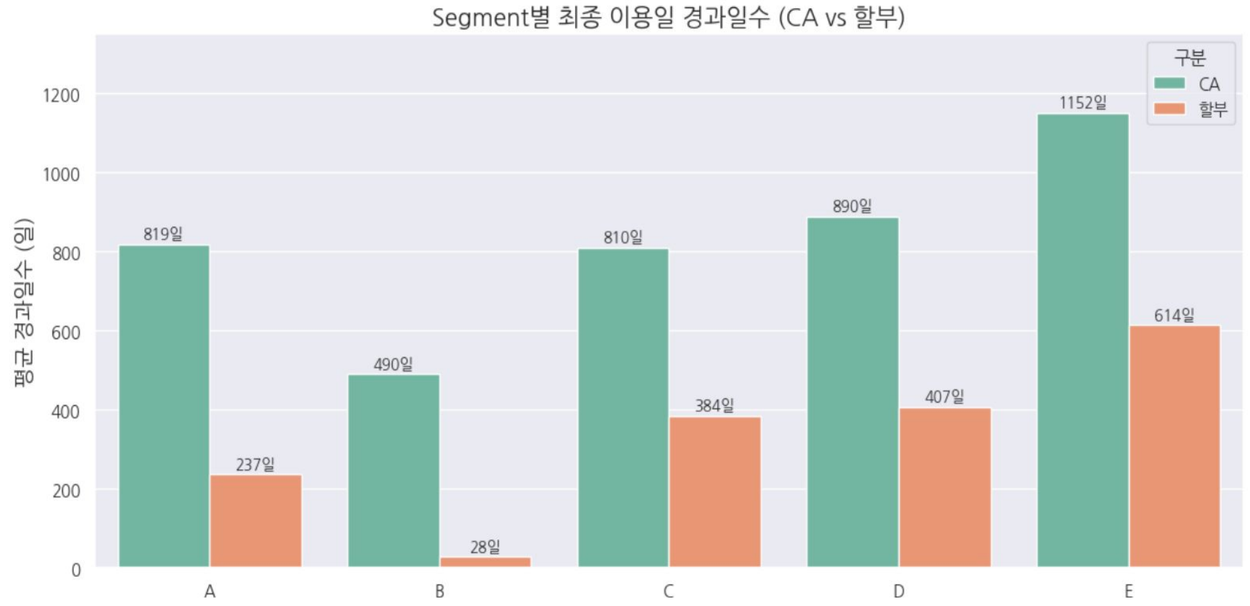
→ Segment가 경제적 여유 / 소비 습관 / 소비 여력 차이를 나타냄

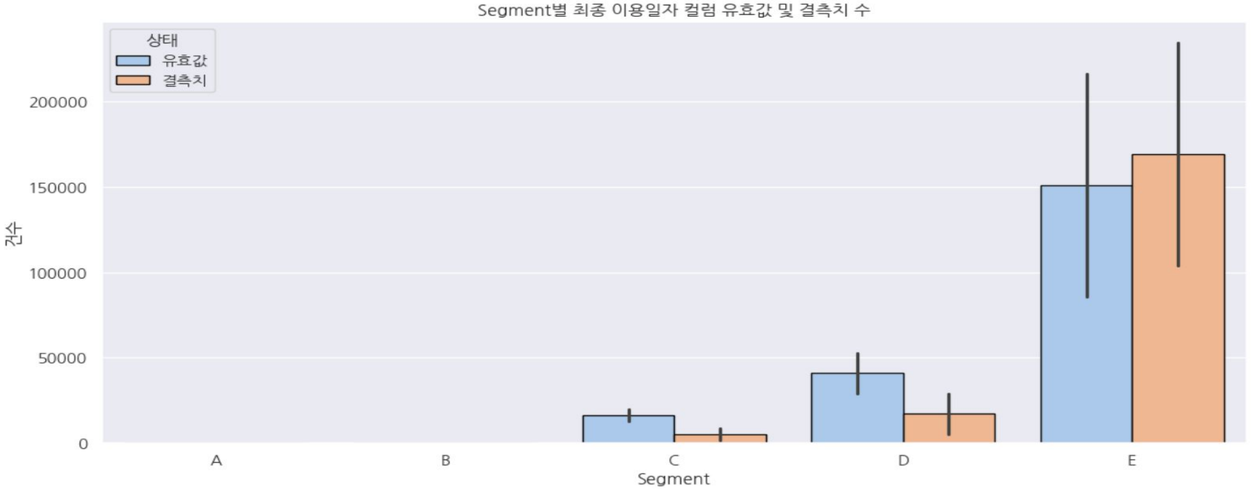
- Segment는 백화점, 마트, 슈퍼, 편의점 등 **생활밀착 소비 항목** 등 실제 생활 소비력에 기반한 분류로 작동

→ 마케팅 전략

Segment A/B : **고소득/고가치 고객**일 가능성
→ 프리미엄 서비스,멤버십, 전용 혜택
Segment C/D : 실속형 소비를 위한 혜택/캐시백 중심 마케팅
Segment E : 소득이 낮거나, **사회초년생** 가능성이 높음 → 소액결제 혜택, 생필품 중심 마케팅

Feature EDA : 최종이용일자_CA , 최종이용일자_할부





→ 우수/활성 고객인지 구분짓는 지표

Segment B

- **최종이용일자_CA** 상대적으로 짧음

  → 최근 신용카드 사용 빈도 높음

- **최종이용일자_할부** 평균 경과일 가장 짧음

  → 최근까지 고가 소비(할부) 활발

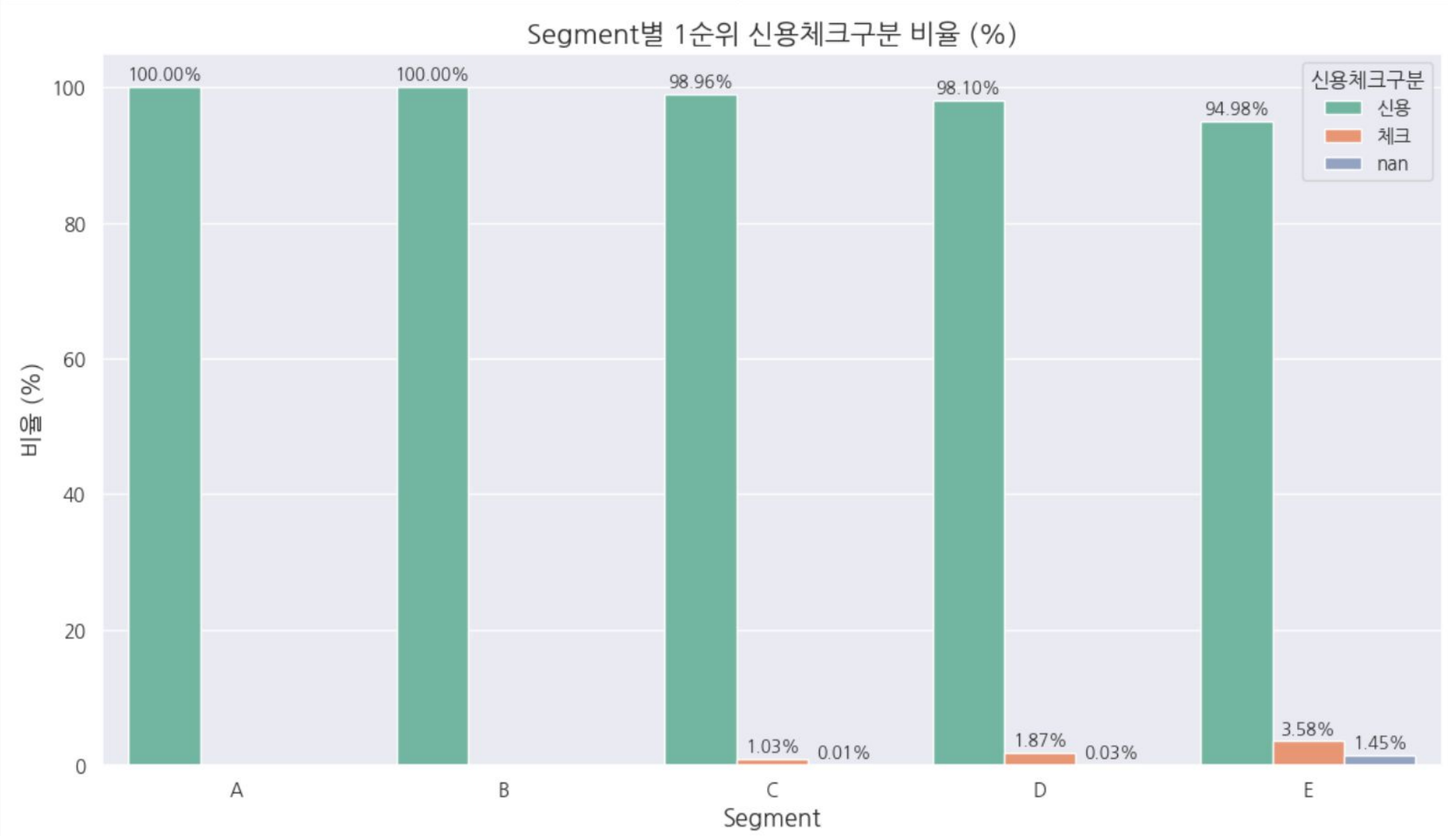
  → 우수 고객 유지: **프리미엄 혜택 / 리워드 강화**

Segment E: 경과일 길고, 결측치 비율 매우 높음

→ 비활성 또는 저활용 고객군으로 해석 가능

→ 재활성화 필요: **리텐션 캠페인 / 혜택 기반 이용 유도**

Feature EDA : 1순위_신용체크구분

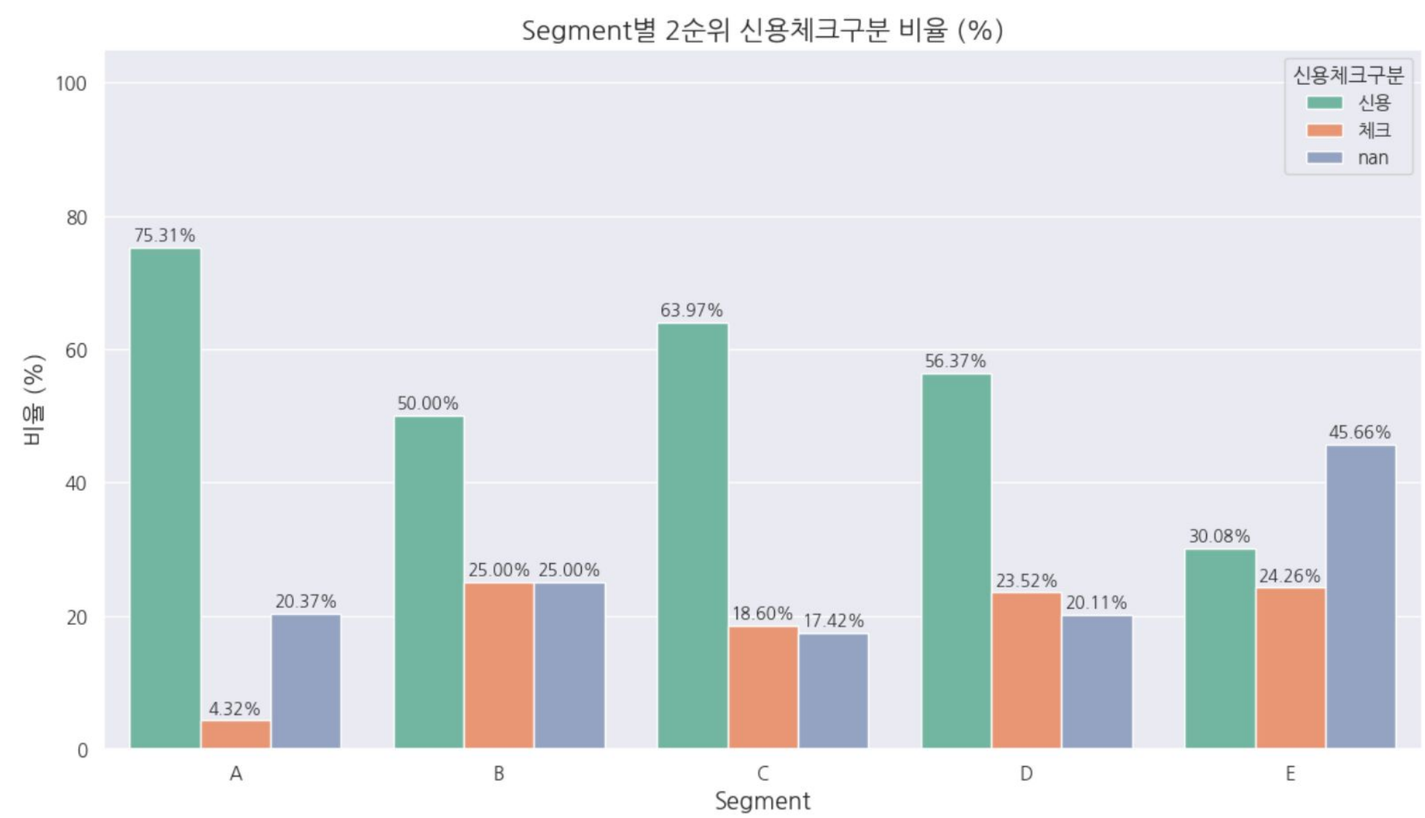


1순위 카드 사용은 대부분 ‘신용’ → 차별성이 없음

- Segment A~D는 거의 100% 신용카드 → 구분력이 떨어짐
- 그래서 1순위 신용체크구분은 Feature Selection에서 탈락

→ 세그먼트 간 차이가 거의 없어 분류에 도움 안 됨

Feature EDA : 2순위_신용체크구분



2순위 카드 사용은 세그먼트별 차이가 뚜렷

→ **구분력 있음**

Segment A : 체크카드보다 신용카드 사용 압도적

Segment B~D: 2순위 카드도 신용카드 선호 → **소비 여력이 있음**, 신용 한도 넉넉

Segment E:

- **신용과 체크 비율 유사**
- **결측치 비율 높음** → 2장 이상 사용 안 할 수도 있음 → **카드 다양성 낮음**

→ 2순위 카드 구분은 **카드 이용 습관, 소비 여력, 고객군 다양성**을 반영

인사이트 및 마케팅 전략제안

1 **Segment A/B는 프리미엄 마케팅 타겟**

- 높은 한도 + 장기 이용 + 신용카드 중심 소비 + 최근까지 사용
- **프리미엄 카드, 리워드 강화, 장기 고객 우대** 마케팅 전략

2 **Segment C/D는 잠재 고가치 고객군**

- 기본적인 신용카드 사용 패턴을 보이며 일정 수준의 소비력을 갖춘 고객군
- **가성비 높은 실속형 혜택 제공, 할인/캐시백 중심 사용 프로모션** 등과 같은 **육성형 마케팅 전략**

3 **Segment E 고객군은 리스크/저소득/신규 비중이 높음**

- 낮은 한도, 짧은 이용기간, 낮은 소비 → **고객 육성이 필요한 대상**
- **저소득층 맞춤 상품, 신용 성장형 상품 제안**, **고객 육성 대상 분류**, **리텐션(이탈 방지) 중심** 마케팅 전략

감사합니다